



UNIVERSIDADE FEDERAL DO AGRESTE DE PERNAMBUCO (PIBIC)

TÍTULO DO PROJETO DE PESQUISA: Processamento de imagem para estimativa do peso de búfalo

TÍTULO DO PLANO DE TRABALHO: Avaliação do método de segmentação semântica por detecção de objeto saliente em imagens digitais de bubalinos

Victor Alexandre Saraiva Pimentel

Avaliação do método de segmentação semântica por detecção de objeto saliente em imagens digitais de bubalinos

Relatório de Victor Alexandre Saraiva Pimentel apresentado à Universidade Federal do Agreste de Pernambuco, vinculado à área de Ciências da Computação, como parte das atividades do Programa PIBIC, sob orientação de Kleber Regis Santoro, no período de 10/07/2025 a 10/04/2026.

SUMÁRIO

1 INTRODUÇÃO	4
2 OBJETIVOS	4
2.1 Objetivo Geral	4
2.2 Objetivos Específicos	4
3 FUNDAMENTAÇÃO TEÓRICA	5
3.1 Visão Computacional na Zootecnia de Precisão	5
3.2 Segmentação Semântica e Detecção de Objetos Salientes	5
3.3 Desafios em Cenários de Campo e Desbalanceamento de Classes	5
3.4 Avaliação de Segmentação Bruta (Escores Probabilísticos)	6
3.5 Binarização, Pós-processamento e Métricas Finais	6
4 METODOLOGIA	6
5 RESULTADOS E DISCUSSÃO / DESENVOLVIMENTO DO TRABALHO	7
5.1 Impacto das Tags de Dificuldade nos Resultados	7
5.2 Estabilidade entre Execuções da Segmentação Bruta	11
5.3 Desempenho dos Modelos na Segmentação Bruta	13
5.4 Desempenho das Estratégias na Segmentação Binarizada	14
5.5 Validação Final dos Melhores Resultados	16
6 CONSIDERAÇÕES PARCIAIS OU FINAIS	17
7 DIFICULDADES ENCONTRADAS	17
8 REFERÊNCIAS BIBLIOGRÁFICAS	17
9 ATIVIDADES DO PLANO DE TRABALHO NÃO REALIZADAS	18
10 PARECER DO(A) ORIENTADOR(A)	19

1 INTRODUÇÃO

Este plano de trabalho insere-se na zootecnia de precisão e na visão computacional aplicada à produção animal, estando vinculado ao projeto “Predição do peso vivo e caracterização de búfalos da raça Murrah usando medidas corporais lineares”. A zootecnia de precisão busca ampliar o monitoramento automatizado e individualizado dos animais por meio de tecnologias digitais, incluindo abordagens baseadas em visão computacional (NORTON et al., 2019). Para automatizar com precisão a estimativa de peso e as medições biométricas por imagens digitais, é necessário isolar o animal do restante da cena, etapa central em sistemas de estimativa de peso baseados em imagem (DOHMEN; CATAL; LIU, 2022). Em imagens capturadas por smartphones em sistemas extensivos e semi-intensivos, essa etapa é dificultada por múltiplos búfalos, oclusões, ângulos extremos e, sobretudo, baixo contraste entre animal e fundo, tornando central a avaliação de métodos de segmentação semântica por detecção de objetos salientes, já que dela depende a qualidade da máscara usada nas etapas posteriores.

O problema de pesquisa consiste em identificar quais modelos pré-treinados apresentam melhor desempenho e estabilidade na segmentação de bubalinos em condições desafiadoras de campo, considerando a qualidade da máscara contínua e o efeito das etapas posteriores de binarização. Como há forte desbalanceamento de classes, com predominância de pixels de fundo, o estudo busca entender quais modelos e estratégias de processamento lidam melhor com essa assimetria sem perder definição de área e contorno do búfalo, já que métricas tradicionais podem se tornar pouco informativas nesse cenário (SAITO; REHMSMEIER, 2015). Parte-se da hipótese de que modelos treinados em bases amplas e generalistas possam adaptar-se melhor ao domínio agropecuário do que modelos voltados a nichos muito específicos.

O estudo foi organizado em duas frentes complementares: a avaliação da qualidade das máscaras contínuas produzidas pelos modelos e a análise do efeito da binarização e do pós-processamento sobre essas máscaras, considerando também as condições de dificuldade presentes nas imagens e os diferentes cenários analíticos do conjunto de dados. Assim, a pesquisa não busca apenas apontar um modelo vencedor, mas identificar quais modelos são mais robustos na segmentação bruta, quais estratégias de binarização melhor se ajustam a cada um e se as melhores combinações já atingem um patamar suficiente de qualidade para segmentação de búfalos em imagens de campo.

2 OBJETIVOS

2.1 Objetivo Geral

O objetivo geral desta pesquisa é avaliar arquiteturas pré-treinadas de segmentação semântica por detecção de objeto saliente em imagens digitais de bubalinos, considerando a qualidade da segmentação bruta e o efeito das estratégias de binarização, a fim de identificar as soluções mais robustas para isolar o animal do fundo em cenários reais de campo e viabilizar a extração futura de medidas corporais e a predição do peso vivo.

2.2 Objetivos Específicos

- Produzir ground truths manuais no GIMP, definindo com precisão a área e o contorno do animal para validar os modelos.
- Realizar a curadoria manual das imagens com tags de dificuldade, como baixo_contraste, ocluido, cortado, angulo_extremo e multi_bufalos, apoiando a análise do impacto dessas condições.

- Comparar modelos pré-treinados das famílias u2net, isnet, sam e birefnets na segmentação de imagens digitais de bubalinos.
- Avaliar estratégias de binarização e pós-processamento morfológico na conversão das máscaras probabilísticas em máscaras binárias finais.
- Calcular AUPRC, Soft Dice, Brier Score, IoU, Precision, Recall, Area Similarity e Perímetro Similarity.
- Medir a estabilidade e a reprodutibilidade da segmentação bruta em execuções repetidas.
- Analisar o impacto das tags de curadoria e comparar os resultados nos cenários de dataset completo, ideal e apenas ok.
- Verificar se as melhores combinações entre modelo e estratégia de binarização atingem qualidade suficiente ou ainda indicam necessidade de retreinamento específico.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 Visão Computacional na Zootecnia de Precisão

A zootecnia de precisão busca otimizar a produção animal por meio de monitoramento automatizado e individualizado (NORTON et al., 2019). Nesse contexto, a biometria por imagem permite estimar o peso vivo de bubalinos sem conduzi-los a balanças físicas, reduzindo estresse, tempo e mão de obra, sendo a visão computacional uma abordagem promissora para esse tipo de estimativa em sistemas pecuários (DOHMEN; CATAL; LIU, 2022). Para isso, porém, o sistema computacional precisa delimitar corretamente o corpo do animal na imagem, separando-o de pastos, cercas e outros ruídos visuais.

3.2 Segmentação Semântica e Detecção de Objetos Salientes

Segmentação semântica é a tarefa de classificar cada pixel da imagem em categorias como búfalo ou fundo. Dentro desse campo, a Detecção de Objetos Salientes (Salient Object Detection - SOD) busca extrair o elemento visualmente mais relevante da cena. Arquiteturas como U²-Net (QIN et al., 2020), IS-Net (QIN et al., 2022), SAM (KIRILLOV et al., 2023) e BiRefNet (ZHENG et al., 2024) ampliaram a capacidade de segmentar objetos em contextos complexos ao combinar contexto global, necessário para reconhecer o animal, com detalhes locais, importantes para refinar bordas.

3.3 Desafios em Cenários de Campo e Desbalanceamento de Classes

Diferentemente de imagens obtidas em ambientes controlados, fotografias de sistemas extensivos e semi-intensivos apresentam ruídos severos, como baixo contraste entre animal e fundo, oclusões, ângulos extremos e presença de múltiplos indivíduos, características compatíveis com os desafios já descritos para aplicações de visão computacional em contextos pecuários reais (DOHMEN; CATAL; LIU, 2022). Além disso, há forte desbalanceamento de classes, pois os pixels do búfalo ocupam parcela muito menor da imagem que os do cenário. Nessa situação, métricas tradicionais como acurácia tornam-se insuficientes, já que um modelo pode parecer bom ao classificar quase tudo como fundo e ainda falhar no objetivo principal da segmentação (SAITO; REHMSMEIER, 2015).

Por isso, métricas mais sensíveis à classe positiva, como AUPRC e Soft Dice, tornam-se mais informativas nesse contexto, pois avaliam com maior precisão a capacidade do modelo de recuperar o objeto de interesse mesmo quando o fundo domina a maior parte da imagem (SAITO; REHMSMEIER, 2015; MILLETARI; NAVAB; AHMADI, 2016).

3.4 Avaliação de Segmentação Bruta (Escores Probabilísticos)

Modelos de detecção de objetos salientes produzem inicialmente máscaras contínuas em escala de cinza, nas quais a intensidade de cada pixel representa a confiança de pertencer ao objeto de interesse: valores próximos de preto indicam fundo, próximos de branco indicam animal e tons intermediários representam incerteza. Para avaliar essa saída antes da aplicação de limiares, os valores são normalizados entre 0 e 1 e analisados por métricas adequadas ao desbalanceamento de classes: AUPRC, que mede a capacidade de priorizar pixels positivos em cenários desbalanceados (SAITO; REHMSMEIER, 2015); Soft Dice, que avalia a sobreposição suave entre predição e ground truth (MILLETARI; NAVAB; AHMADI, 2016); e Brier Score, que quantifica o erro quadrático médio entre a confiança predita e o valor real (BRIER, 1950).

3.5 Binarização, Pós-processamento e Métricas Finais

Para uso nas etapas posteriores de biometria, a máscara contínua deve ser convertida em máscara binária, atribuindo valor máximo aos pixels do animal e zero ao fundo. Esse processo de limiarização pode introduzir ruídos, descontinuidades e bordas serrilhadas, motivo pelo qual se aplicam filtros e operações morfológicas, como suavização gaussiana, abertura e fechamento. Entre os métodos de limiarização, o procedimento de Otsu destaca-se por estimar automaticamente o limiar a partir da distribuição dos níveis de cinza da imagem (OTSU, 1979). Neste projeto, a binarização é parte da própria avaliação, pois pode preservar ou degradar o potencial da máscara contínua. Por isso, as máscaras finais são comparadas ao ground truth por IoU, Precision, Recall, Area Similarity e Perímetro Similarity, permitindo avaliar tanto a sobreposição espacial quanto a preservação de área e contorno, aspecto crítico para medições corporais em bubalinos (TAHA; HANBURY, 2015).

Cada uma dessas métricas destaca uma dimensão específica da qualidade da segmentação final. A IoU mede a sobreposição entre a máscara predita e o ground truth, sintetizando o quanto ambas coincidem espacialmente. A Precision indica o quanto dos pixels classificados como animal realmente pertencem ao animal, sendo sensível a falsos positivos. A Recall mostra o quanto da área real do búfalo foi recuperada pela segmentação, sendo sensível a falsos negativos. A Area Similarity avalia a preservação da área global do objeto segmentado, enquanto a Perímetro Similarity observa o quanto o contorno final se mantém compatível com o da referência manual. Em conjunto, essas métricas permitem avaliar não apenas se a segmentação encontra o animal, mas também se o faz com fidelidade geométrica suficiente para aplicações biométricas posteriores (TAHA; HANBURY, 2015).

4 METODOLOGIA

Trata-se de um estudo quantitativo e experimental em visão computacional, voltado à avaliação de modelos pré-treinados de segmentação semântica por detecção de objetos salientes para isolar bubalinos do fundo em fotografias de campo. A base reúne imagens .jpg capturadas por smartphones de búfalos da raça Murrah em sistemas extensivos e semi-intensivos de Pernambuco. A amostra analisada nesta etapa foi composta por 387 imagens, todas compatíveis com o recorte do estudo e com as condições de campo investigadas. Nesta etapa, realizou-se a curadoria manual da base por meio de interfaces em Python com tkinter, com atribuição das tags multi_bufalos, cortado, angulo_extremo, baixo_contraste e ocluido, além da criação do ground truth por segmentação manual no GIMP (THE GIMP DEVELOPMENT TEAM, 2026).

O processamento foi automatizado em um pipeline em Python responsável pela inferência dos modelos, binarização das máscaras, cálculo das métricas e organização das saídas analíticas (PIMENTEL, 2026). A geração das máscaras preditivas foi feita com apoio da biblioteca rembg, usada como interface para modelos pré-treinados das famílias u2net, isnet, sam, silueta e birefnet

(GATIS, 2025). As máscaras contínuas foram então submetidas a quatro estratégias de binarização e refinamento: Limiar Fixo, Otsu, Gaussian Opening e Hysteresis Closing. No Limiar Fixo, classificaram-se como pertencentes ao búfalo os pixels com valor igual ou superior a 0,5. No método de Otsu, esse limiar é estimado automaticamente a partir da distribuição dos tons de cinza da própria máscara (OTSU, 1979). Já as estratégias com Gaussian Opening e Hysteresis Closing incorporam etapas adicionais de suavização e refinamento estrutural, buscando reduzir ruídos, pequenos fragmentos indevidos e irregularidades nas bordas. As configurações denominadas como Alta e Baixa correspondem a parametrizações distintas dessas estratégias, representando versões mais conservadoras ou mais permissivas no processo de binarização e pós-processamento, de modo a verificar como diferentes níveis de rigidez afetam a preservação da área e do contorno do animal. De modo geral, as configurações Baixa tendem a operar com critérios menos restritivos, favorecendo maior recuperação da área do objeto, enquanto as configurações Alta tendem a impor critérios mais rigorosos de separação e refinamento, o que pode reduzir ruídos, mas também aumentar o risco de perda de partes válidas do animal. A comparação entre essas variantes permitiu avaliar o equilíbrio entre preservação estrutural e limpeza da máscara final.

Para preservar a fidelidade do contorno manual de referência, o ground truth não recebeu pós-processamento morfológico, sendo convertido apenas por uma estratégia fixa de limiarização. O ground truth foi mantido o mais próximo possível da anotação manual original, pois sua função metodológica é servir como referência estável para a avaliação dos modelos, e não como resultado a ser refinado por processamento. A aplicação de operações morfológicas nessa máscara poderia alterar artificialmente propriedades geométricas relevantes, como área, contorno e sobreposição, comprometendo a comparabilidade com as saídas preditivas. Por essa razão, o pós-processamento foi restrito às máscaras geradas pelos modelos, enquanto o ground truth recebeu apenas a conversão binária necessária à padronização da referência.


Com base nas tags, a análise foi organizada nos cenários dataset completo, ideal e apenas ok. Após a verificação de estabilidade, adotou-se uma execução fixa configurável para a etapa binarizada, e os resultados foram armazenados em SQLite. Ao final, as combinações mais promissoras foram validadas por thresholds absolutos nas métricas da segmentação binarizada.

5 RESULTADOS E DISCUSSÃO / DESENVOLVIMENTO DO TRABALHO

5.1 Impacto das Tags de Dificuldade nos Resultados


Esta subseção analisa como as tags de curadoria afetam a segmentação bruta e binarizada. As tags descrevem dificuldades visuais da cena: `baixo_contraste`, `angulo_extremo`, `cortado`, `multi_bufalos`, `ocluido` e `ok`. Sua leitura permite identificar não apenas o desempenho médio dos modelos e estratégias, mas também em quais condições ele se degrada.

Figura 1 - Interação entre modelo e tags de dificuldade na métrica AUPRC.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 2 - Interação entre modelo e tags de dificuldade na métrica Soft Dice.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 3 - Interação entre modelo e tags de dificuldade na métrica Brier Score.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 4 - Interação entre estratégia de binarização e tags de dificuldade na métrica Precision.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 5 - Interação entre estratégia de binarização e tags de dificuldade na métrica Recall.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 6 - Interação entre estratégia de binarização e tags de dificuldade na métrica de similaridade de área.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 7 - Interação entre estratégia de binarização e tags de dificuldade na métrica IoU.



Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 8 - Interação entre estratégia de binarização e tags de dificuldade na métrica de similaridade de perímetro.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Na segmentação bruta, as métricas AUPRC, Soft Dice e Brier Score mostraram impacto negativo consistente de baixo_contraste, multi_bufalos e ocluido, coerente com a maior dificuldade de separar objeto e fundo, reduzir ambiguidades e preservar contornos. Já angulo_extremo e cortado não apresentaram deterioração suficientemente consistente para justificar sua exclusão do cenário ideal. Na segmentação binarizada, IoU, Precision, Recall, Area Similarity e Perímetro Similarity

mantiveram o mesmo padrão geral, embora com intensidade variável entre métricas. Com base nesses resultados, definiram-se três cenários analíticos: dataset completo; cenário ideal, que mantém imagens ok, angulo_extremo e cortado; e cenário apenas ok, restrito às imagens sem dificuldades anotadas.


5.2 Estabilidade entre Execuções da Segmentação Bruta

Figura 9 - Estabilidade entre execuções dos modelos de segmentação bruta em AUPRC.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 10 - Estabilidade entre execuções dos modelos de segmentação bruta em Soft Dice.



Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 11 - Estabilidade entre execuções dos modelos de segmentação bruta em Brier Score.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Antes de comparar modelos e estratégias de binarização, verificou-se a estabilidade entre execuções da segmentação bruta por meio do coeficiente de variação entre execuções (cv_execucoes). Os resultados mostraram valores nulos ou residuais em AUPRC, Soft Dice e Brier Score, mesmo nos casos de maior dispersão, indicando elevada repetibilidade experimental. Assim, as diferenças entre modelos refletem seu comportamento intrínseco, e não flutuações relevantes do processo, o que justifica o uso de uma execução fixa nas análises posteriores.

5.3 Desempenho dos Modelos na Segmentação Bruta

Figura 12 - Ranking geral dos modelos de segmentação bruta nos cenários dataset completo, cenário ideal e apenas ok.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Com as dificuldades relevantes identificadas e a estabilidade confirmada, comparou-se o desempenho dos modelos na segmentação bruta nos cenários dataset completo, ideal e apenas ok, usando ranking multivariado baseado em AUPRC, Soft Dice e Brier Score, sintetizado pelo mean_rank. No dataset completo, destacaram-se birefnet-general e birefnet-hrsod, seguidos por outras variantes BiRefNet, isnet-general-use e u2netp, enquanto sam e isnet-anime ficaram nas últimas posições. No cenário ideal e no cenário apenas ok, birefnet-hrsod assumiu e manteve a liderança, indicando maior consistência em condições favoráveis, enquanto birefnet-general permaneceu altamente competitivo, sobretudo no dataset completo. Em conjunto, os resultados mostram que a família BiRefNet concentrou os melhores desempenhos da segmentação bruta e fundamenta a análise da etapa binarizada.


5.4 Desempenho das Estratégias na Segmentação Binarizada

Figura 13 - Melhor binarização por modelo no cenário do dataset completo.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 14 - Melhor binarização por modelo no cenário ideal.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 15 - Melhor binarização por modelo no cenário de apenas ok.



Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 16 - Top 15 combinações modelo + estratégia nos cenários dataset completo, cenário ideal e apenas ok.




Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Após a segmentação bruta, investigou-se como a binarização afeta o desempenho final, buscando a melhor estratégia para cada modelo nos cenários dataset completo, ideal e apenas ok. O ranking multivariado foi construído com IoU, Precision, Recall, Area Similarity e Perímetro Similarity. Os heatmaps mostram que a melhor binarização varia conforme o modelo: no dataset completo, LimiarFixoBaixa predominou entre os modelos mais fortes, como birefnet-general, birefnet-hrsod, birefnet-massive, birefnet-portrait e silueta; HistereseClosingBaixa e HistereseClosingAlta também se destacaram em casos específicos; e OtsuOpeningBaixa/Alta apareceram mais em modelos como isnet-anime, u2net_human_seg e u2netp. No cenário ideal, LimiarFixoBaixa se consolidou entre várias variantes de BiRefNet, enquanto HistereseClosingBaixa favoreceu birefnet-general-lite e birefnet-massive, e HistereseClosingAlta favoreceu isnet-general-use. No cenário apenas ok, LimiarFixoBaixa tornou-se ainda mais frequente entre os modelos mais bem posicionados, enquanto OtsuOpeningAlta apareceu mais em modelos intermediários ou fracos. O top 15 de combinações modelo + estratégia confirma que as melhores posições se concentram nos modelos já fortes na etapa bruta, especialmente birefnet-general e birefnet-hrsod. Assim, não há uma estratégia universalmente ótima: o desempenho final depende da compatibilidade entre o perfil de saída do modelo e a binarização adotada.


5.5 Validação Final dos Melhores Resultados

Figura 17 - Desempenho médio das combinações finalistas nas métricas da segmentação binarizada.



Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Figura 18 - Aprovação das combinações finalistas nos thresholds configurados para a validação final.



Fonte: Elaborado pelo autor com base nos dados da pesquisa (2026).

Na validação final, selecionaram-se os três modelos mais bem posicionados na segmentação bruta

do cenário apenas ok — birefnetsod, birefnets-general e birefnets-massive — e, para cada um, a melhor estratégia de binarização no mesmo cenário, que foi LimiarFixoBaixa nos três casos. As combinações foram avaliadas por thresholds absolutos de IoU ($\geq 0,97$), Precision ($\geq 0,99$), Recall ($\geq 0,985$), Area Similarity ($\geq 0,99$) e Perímetro Similarity ($\geq 0,96$), definidos como critério rigoroso de suficiência. Como todas atenderam simultaneamente a esses limites, conclui-se que, no recorte mais favorável, o pipeline já produz segmentações de alta qualidade, sem evidência imediata de necessidade de retreinamento específico, embora essa possibilidade possa ser revista em etapas futuras mais exigentes.

6 CONSIDERAÇÕES PARCIAIS OU FINAIS

Os resultados desta etapa indicam que os objetivos do plano de trabalho foram alcançados. Foi estruturado um pipeline completo de avaliação para segmentação de bubalinos em imagens de campo, desde a produção do ground truth manual até a comparação de modelos de segmentação bruta, estratégias de binarização e critérios finais de validação. Na segmentação bruta, destacou-se um grupo superior liderado por variantes da família BiRefNet, especialmente birefnetsod, birefnets-general e birefnets-massive, além de se confirmar a estabilidade do pipeline e o impacto negativo consistente de baixo_contraste, multi_bufalos e ocluido. Na segmentação binarizada, verificou-se que a melhor estratégia depende da interação entre o modelo e a distribuição de scores, embora LimiarFixoBaixa tenha se destacado entre os modelos mais fortes. Por fim, a validação final mostrou que os três melhores modelos no cenário apenas ok, combinados com sua melhor binarização, atenderam aos thresholds absolutos definidos, indicando que o pipeline já alcança alto padrão de qualidade nesse recorte, sem evidência imediata de necessidade de retreinamento específico.

7 DIFICULDADES ENCONTRADAS

Durante esta etapa, as principais dificuldades foram a construção do ground truth, a curadoria manual das imagens, o custo computacional do pipeline e a escala combinatória da análise binarizada. A segmentação manual das máscaras de referência e o tagging das dificuldades visuais demandaram tempo e cuidado, pois afetam diretamente a confiabilidade das métricas e a interpretação estatística. Além disso, a execução dos modelos, a geração das máscaras, a binarização, o recálculo das métricas e as execuções múltiplas exigiram processamento significativo, impactando o ritmo de experimentação. Na segmentação binarizada, a combinação entre múltiplos modelos, estratégias e execuções elevou rapidamente o custo analítico, exigindo adaptações metodológicas, como o uso de uma execução fixa configurável e a reorganização dos artefatos analíticos. Essas dificuldades não impediram o avanço do trabalho, mas influenciaram diretamente a organização metodológica adotada.

8 REFERÊNCIAS BIBLIOGRÁFICAS

BRIER, Glenn W. Verification of forecasts expressed in terms of probability. Monthly Weather Review, [S. l.], v. 78, n. 1, p. 1-3, 1950. DOI: [https://doi.org/10.1175/1520-0493\(1950\)078<0001:VOFEIT>2.0.CO;2](https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2).

DICE, Lee R. Measures of the amount of ecologic association between species. Ecology, [S. l.], v. 26, n. 3, p. 297-302, 1945. DOI: <https://doi.org/10.2307/1932409>.

DOHMEN, R.; CATAL, C.; LIU, Q. Computer vision-based weight estimation of livestock: a systematic literature review. New Zealand Journal of Agricultural Research, [S. l.], 2022. DOI: <https://doi.org/10.1080/00288233.2021.1876107>.

GATIS, Daniel. rembg. [S. l.], 2025. Disponível em: <https://github.com/danielgatis/rembg>. Acesso em: 10 abr. 2026.

KIRILLOV, Alexander et al. Segment Anything. In: IEEE/CVF INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2023. Proceedings [...]. [S. l.]: IEEE/CVF, 2023. p. 4015-4026. DOI: <https://doi.org/10.1109/ICCV51070.2023.00371>.

MILLETARI, Fausto; NAVAB, Nassir; AHMADI, Seyed-Ahmad. V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation. In: 2016 FOURTH INTERNATIONAL CONFERENCE ON 3D VISION (3DV). Proceedings [...]. [S. l.]: IEEE, 2016. p. 565-571. DOI: <https://doi.org/10.1109/3DV.2016.79>.

NORTON, T.; CHEN, C.; LARSEN, M. L. V.; BERCKMANS, D. Review: Precision livestock farming: building ‘digital representations’ to bring the animals closer to the farmer. *Animal*, v. 13, n. 12, p. 3009-3017, 2019. DOI: <https://doi.org/10.1017/S175173111900199X>.

OTSU, Nobuyuki. A Threshold Selection Method from Gray-Level Histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, [S. l.], v. 9, n. 1, p. 62-66, 1979. DOI: <https://doi.org/10.1109/TSMC.1979.4310076>.

PIMENTEL, Victor Alexandre Saraiva. Projeto-bufalos: repositório com scripts e pipeline de processamento de imagens para o projeto. GitHub, 2026. Disponível em: <https://github.com/Victor-Saraiva-P/Projeto-bufalos>. Acesso em: 14 abr. 2026.

QIN, Xuebin et al. Highly Accurate Dichotomous Image Segmentation. In: COMPUTER VISION – ECCV 2022. Proceedings [...]. [S. l.]: Springer, 2022. p. 38-56. DOI: https://doi.org/10.1007/978-3-031-19797-0_3.

QIN, Xuebin et al. U²-Net: Going deeper with nested U-structure for salient object detection. *Pattern Recognition*, [S. l.], v. 106, p. 107404, 2020. DOI: <https://doi.org/10.1016/j.patcog.2020.107404>.

SAITO, Takaya; REHMSMEIER, Marc. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, [S. l.], v. 10, n. 3, e0118432, 2015. DOI: <https://doi.org/10.1371/journal.pone.0118432>.

TAHA, A. A.; HANBURY, A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool. *BMC Medical Imaging*, v. 15, art. 29, 2015. DOI: <https://doi.org/10.1186/s12880-015-0068-x>.

THE GIMP DEVELOPMENT TEAM. GNU Image Manipulation Program (GIMP). [S. l.], 2026. Disponível em: <https://www.gimp.org/>. Acesso em: 10 abr. 2026.

ZHENG, Peng et al. Bilateral Reference for High-Resolution Dichotomous Image Segmentation. *CAAI Artificial Intelligence Research*, [S. l.], v. 3, n. 1, p. 9150038, 2024. DOI: <https://doi.org/10.26599/AIR.2024.9150038>.

9 ATIVIDADES DO PLANO DE TRABALHO NÃO REALIZADAS

Por se tratar de um relatório parcial, ainda não foram concluídos o fechamento final da análise dos resultados, o aprofundamento da discussão comparativa e a consolidação definitiva das interpretações do estudo. Também não foi realizada, nesta etapa, uma fase de ajuste fino ou retreinamento específico dos modelos, uma vez que o foco esteve na avaliação comparativa de

arquiteturas pré-treinadas, das estratégias de binarização e da validação dos melhores resultados. Além disso, o modelo `u2net_cloth_seg` deixou de integrar a configuração ativa de análise devido à sua inadequação ao domínio das imagens de búfalos. Essas frentes deverão ser retomadas nas etapas seguintes da pesquisa.

10 PARECER DO(A) ORIENTADOR(A)

Aqui deve ter um texto de anuência do(a) orientador(a).

**Garanhuns, ____de ____de
2026.**

Assinatura **do(a)**
Orientador(a)

Assinatura do(a) Discente